



Verantwortung für Deutschland

Koalitionsvertrag zwischen
CDU, CSU und SPD

21. Legislaturperiode

144 Seiten
4588 Textzeilen

ALEPH ALPHA – CASE STUDY

Wie RAG den öffentlichen Sektor mit Antworten versorgt

Max Lautenbach · 28. April 2025


WAS IST RAG?

LLMs haben keinen Zugriff auf Unternehmensspezifische Daten



WAS IST RAG?


RAG kann LLMs Zugriff zu Unternehmensspezifische Daten herstellen



Demo

TECHNISCHE UMSETZUNG

Dokumente müssen zunächst vorverarbeitet werden



Unterstützte Dokumente


PDF
JSON
Markdown
Word
HTML

Character Splitter

Chunk Größe: 512 Chars
Overlap: 50 Chars

Embedding Model

bge-m3




Vector DB

Qdrant (via Docker)


TECHNISCHE UMSETZUNG

RAG kann end-to-end Open-Source umgesetzt werden




TECHNISCHE UMSETZUNG

Frontend und Backend können getrennt umgesetzt werden.



TECHNISCHE UMSETZUNG

RAG hat verschiedene Optimierungspunkte



Vorteile von RAG

①

Zugriff auf interne Daten

RAG-Chains können auf semantisch relevante interne Daten zugreifen.

②

Aktualisierung ohne Re-Trainieren

RAG-Chain können das Wissen eines Chatbots aktualisieren ohne das LLM anpassen zu müssen.

③

Kosteneffizienz

RAG-Chains sind meist kosteneffizienter als alternative Optionen.